



Линейная регрессия

Неформальная постановка задачи




- провести прямую, которая проходит как можно ближе к этим точкам в совокупности

Неформальная постановка задачи




- провести прямую, которая проходит как можно ближе к этим точкам в совокупности

Неформальная постановка задачи



- пример оценки значения в задаче

Неформальная постановка задачи



- минимизация суммы отклонений эмпирических значений от теоретических


Линейная регрессия

- Строит линейную поверхность в качестве решения
- Ответ – взвешенная сумма значений признаков

$$\hat{y}(w, x) = w_0 + w_1x_1 + \dots + w_px_p$$


- Определяется $p + 1$ параметром w_i , которые нужно найти по обучающей выборке

Результат линейной регрессии не всегда «прямой»



- Замечание: линейная регрессия может моделировать нелинейную зависимость, используя модификации признаков
- Для примера: в качестве признака выбран квадрат стажа

Результат линейной регрессии не всегда «прямой»



- Замечание: линейная регрессия может моделировать нелинейную зависимость, используя модификации признаков
- Для примера: в качестве признака выбран квадрат стажа

Метод наименьших квадратов

- Минимизация $MSE = \sum_{k=0}^n (y_k - \hat{y}_k)^2 / n$
- В матричной форме $(y - Xw)^T (y - Xw)$, где X – матрица данных (строки – наблюдения, столбцы – признаки), y – вектор известных ответов, w – коэффициенты (веса) модели.
- Условие минимума – равенство нулю производной по w , откуда
- $-2X^T (y - Xw) = 0$, или

$$w = (X^T X)^{-1} X^T y$$
$$\hat{y} = Xw = X(X^T X)^{-1} X^T y$$

Линейная регрессия

- Хорошо работает, если зависимость между целевой переменной и признаками имеет линейный характер
- Хорошо интерпретируется
- Перед использованием нужно провести нормализацию данных
- Не работает с пропусками в данных
- Если между признаками есть высокая корреляция, то решение неустойчиво

Регуляризация

- Дисперсия – это способность модели реагировать на незначительные колебания в тренировочных данных
- Высокая дисперсия приводит к переобучению – ситуации, когда построенная модель хорошо работает на обучающей выборке, но относительно плохо работает на примерах, не участвовавших в обучении
- Решение – использование регуляризации – подавления весов



L2 – регуляризация (Ridge-регрессия)

- $L(w)$ – функция потерь
- $L_2 = L(w) + \lambda \sum_{j=0}^s w_j^2$
- λ – параметр регуляризации, коэффициент штрафа модели
- чем крупнее вес, тем он крупнее штрафуется

L1 – регуляризация (Lasso)

- $L(w)$ – функция потерь
- $L_2 = L(w) + \lambda \sum_{j=0}^s |w_j|$

Сравнение L1 и L2



Регуляризация

- Повышает стабильность модели
- Помогает в борьбе с переобучением
- L2 регуляризация имеет более «мягкий» отбор признаков
- Иногда применяется комбинация L1 и L2 – Elastic Net
- Может быть применена к линейной регрессии, логистической регрессии и не только
- Лучше работает с нормализованными признаками

Выводы

- Линейные модели крайне редко показывают достойный результат сами по себе
- Однако они хорошо работают для разведочного анализа (в т.ч. в силу интерпретируемости):
 - Определение наличия связи между признаками и характера этой связи
 - Определение силы и направления зависимости переменных
 - Отбор важных признаков

Корреляция — статистическая взаимосвязь двух или более случайных величин, при этом изменения значений одной или нескольких из этих величин сопутствуют систематическому изменению значений другой или других величин.

$$r_{xy} = \frac{\sum (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}}$$

Коэффициент корреляции:

- может принимать значения от -1 до +1
- знак коэффициента показывает направление связи (прямая или обратная)
- абсолютная величина показывает силу связи