Практика 5

Ансамблевые методы машинного обучения ч.1

Цели занятия

- Разобрать ансамблевые методы машинного обучения
  - Стекинг
  - Беггинг
  - ~~Бустинг~~
- Кросс-валидация

Основная идея

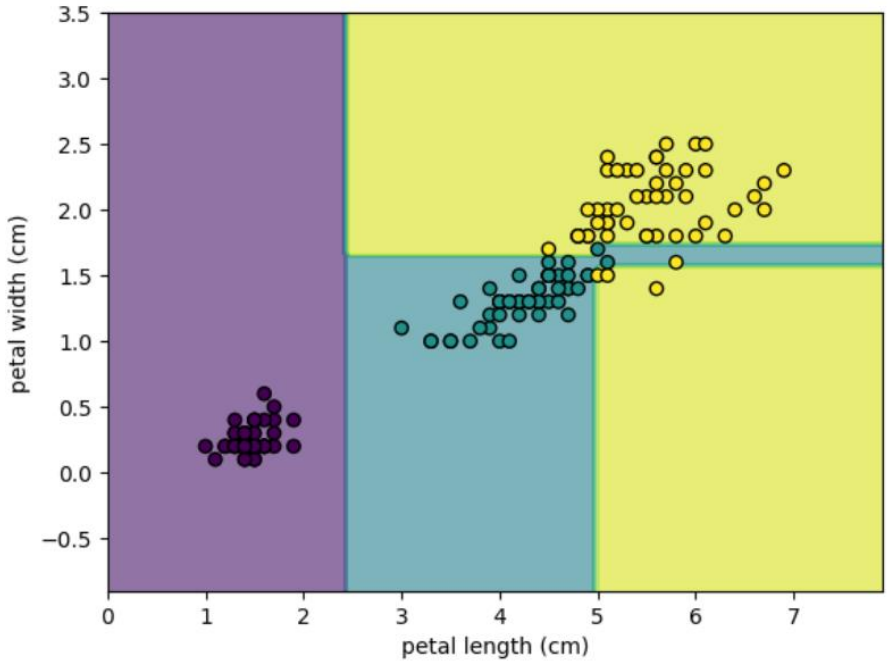
- строятся базовые модели, отличающиеся друг от друга
- агрегация прогнозов в ансамбль с применением мета-алгоритма

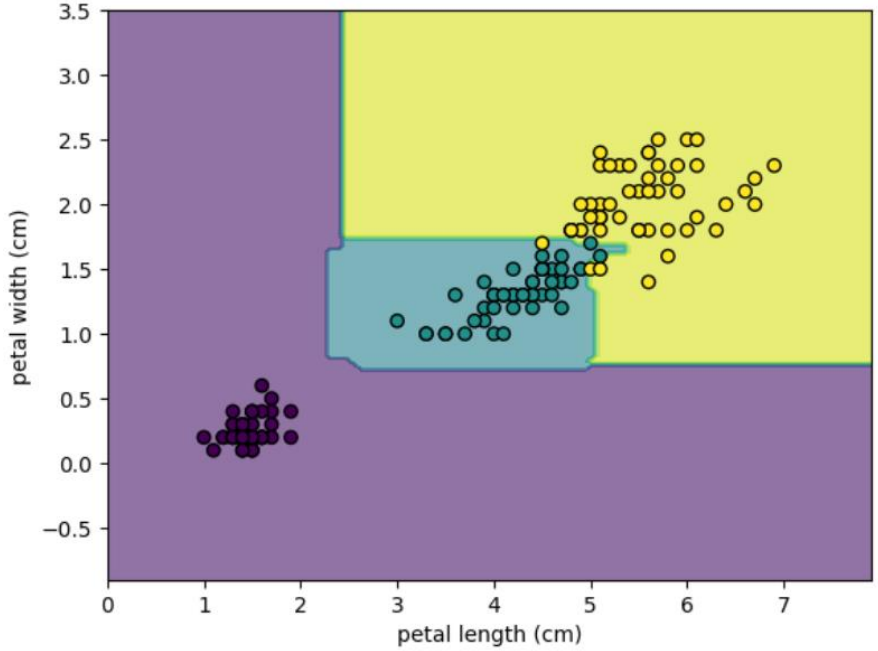
Итог: борьба как с недообучением, так и переобучением



Теорема Кондорсе «о жюри присяжных»

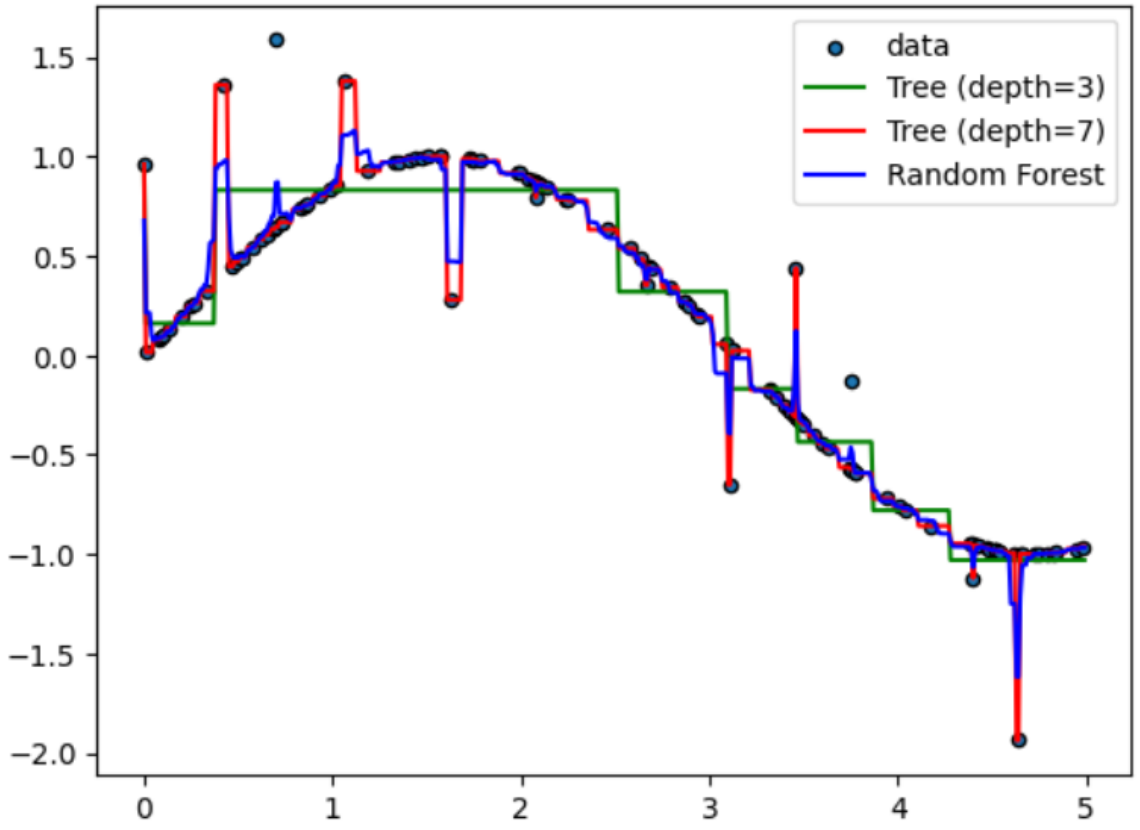
- Если каждый член жюри присяжных имеет независимое мнение, и если вероятность правильного решения члена жюри больше 0.5, то вероятность правильного решения присяжных с увеличением количества членов жюри стремится к единице.





Концепция «мудрость толпы»

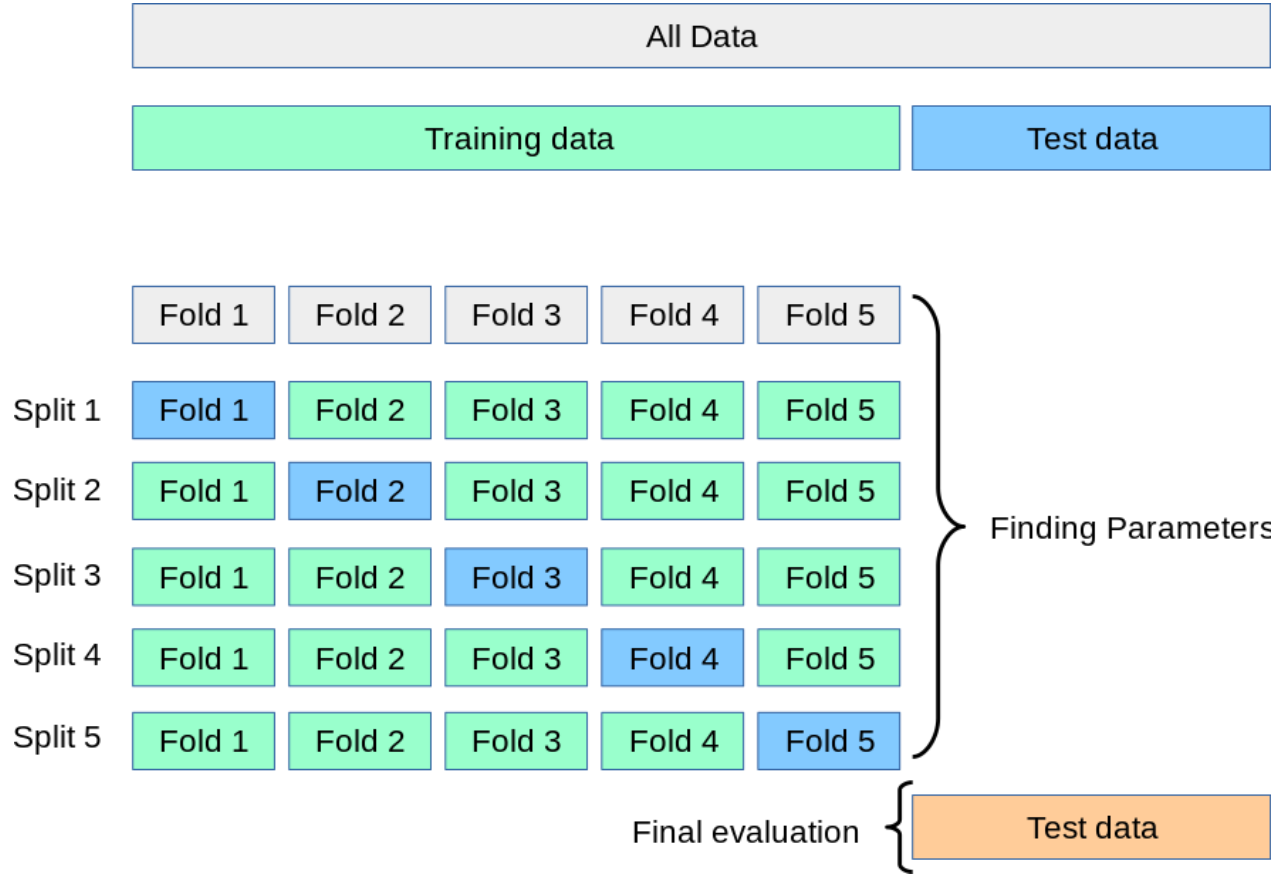
- Группа людей найдет более правильный ответ на вопрос, чем каждый человек в толпе в отдельности
- Чем больше людей принимает участие в решении проблемы, тем ближе к идеальному будет результат.



Кросс-валидация

K-fold кросс-валидация: данные делятся на k равных частей (или фолдов), затем происходит k итераций: каждый фолд используется для тестирования, а остальные k-1 объединяются для обучения модели.

Финальный результат модели получается либо усреднением k получившихся тестовых результатов, либо измеряется на отложенном тестовом множестве, не участвовавшем в кросс-валидации.



Типы ансамблей

- Голосование/усреднение
  - По агрегации: простое/взвешенное/смесь экспертов
  - По вариации выборки:
    - Выборка подмножества строк – **bagging** (bootstrap aggregation)
    - Выборка подмножества признаков
    - Кросс-валидация
- Stacking
  - Простой обучаемый мета-алгоритм на комбинации откликов базовых алгоритмов (и, возможно, признаков выборки)
- Boosting
  - каждый следующий алгоритм пытается исправить ошибку предыдущих

Bagging

- Генерация K выборок с возвращением, на каждой обучается своя базовая модель
- Прогноз происходит на каждой базовой модели с усреднением

Out-of-bag error:

- Вероятность, что объект не попадает в обучающую выборку модели ≈37%
- На ней можно сделать OOB-прогноз, а значит и оценку модели

Random Forest

- Применение бэггинга для обучения моделей
- Случайные подпространства признаков для каждой модели
- Медленно, но распараллеливается

Параметры Random Forest

- Размер ансамбля (не склонен к переобучению)
- Число случайных признаков для разбиения (корень из их кол-ва)
- Пропорция для bootstrap
- Параметры дерева (глубина, минимальный размер листа)

Random Forest

Достоинства:

- не склонен к переобучению
- не так много гиперпараметров (которые надо тюнить)
- распараллеливается

Недостатки:

- неинтерпретируемость
- вычислительная сложность (для прогноза)

Стекинг

- Мета-алгоритм, обучаемый на результатах базовых моделей
- Сильно зависит от качества моделей
- Мета-алгоритм легко переобучается



Стекинг

Два основных подхода:

- Обучение мета-модели на ответах базовых моделей на той же тренировочной выборке
- Обучение мета-модели на ответах базовых моделей на другой выборке